

# Reporte Ejecutivo – Predicción de Hospitalización

Alberto Camacho Espinosa - 6A CDIA A9 - 28/05/2026

## Abstract

Este informe resume los resultados de un modelo predictivo de machine learning desarrollado para el Centro de Salud Digital del Estado de Nayarit, orientado a anticipar la necesidad de hospitalización de pacientes a partir de sus signos vitales y antecedentes clínicos.

### 1. 01 RESUMEN EJECUTIVO

Este informe resume los resultados de un modelo predictivo de machine learning desarrollado para el **Centro de Salud Digital del Estado de Nayarit**, orientado a anticipar la necesidad de hospitalización de pacientes a partir de sus signos vitales y antecedentes clínicos capturados en consulta.

Se analizaron **1,010 registros históricos**, se aplicó limpieza y estandarización completa, se balancearon las clases minoritarias y se entrenaron **Árbol de Decisión** y **Naive Bayes** con las **10 características más relevantes** seleccionadas por SelectKBest.

El **Árbol de Decisión** es el modelo recomendado, con **F1-Score = 0.8308** y **AUC = 0.8169**, logrando una sensibilidad del **90.27 %** que garantiza la detección oportuna de pacientes en riesgo real de hospitalización.

| Campo                | Detalle                                                            |
|----------------------|--------------------------------------------------------------------|
| <b>Análisis</b>      | Predicción de Hospitalización – Centro de Salud Digital de Nayarit |
| <b>Dataset</b>       | dataset_salud_nayarit – 1,010 registros de consulta                |
| <b>Variable obj.</b> | hospitalizacion (0 = no hospitalizado, 1 = hospitalizado)          |
| <b>Autor</b>         | Alberto Camacho Espinosa                                           |
| <b>Grupo</b>         | 6.º Semestre – CONALEP                                             |
| <b>Fecha</b>         | Junio 2026                                                         |
| <b>Metodología</b>   | CRISP-DM                                                           |
| <b>Herramientas</b>  | Python, pandas, scikit-learn, matplotlib, seaborn                  |

Published Jun 17, 2026

### 2. 02 DESCRIPCIÓN DEL PROBLEMA

#### 2.a. Pregunta de negocio

¿Es posible predecir con precisión, antes del alta en consulta, qué pacientes requerirán hospitalización a partir de sus signos vitales y antecedentes clínicos capturados en la primera valoración?




## 2.b. Contexto organizacional

El Centro de Salud Digital del Estado de Nayarit atiende a la población en múltiples municipios. La decisión de hospitalización depende actualmente del criterio clínico del personal en turno, exponiendo al sistema a riesgos de sub-detección en horas pico o por fatiga del personal.



2.c. Alcance del dataset


1,010 registros de consulta provenientes de unidades médicas de Nayarit.



2.d. Balance de clases

La clase “no hospitalizado” es mayoritaria. Se aplicó técnica de sobremuestreo (oversampling) sobre la clase minoritaria antes del entrenamiento, evitando que el

modelo optimice erróneamente la exactitud global ignorando a los pacientes de alto riesgo.



### 3. 03 METODOLOGÍA (CRISP-DM)

#### 3.a. 1. Comprensión del Negocio

El proyecto se estructuró bajo la metodología CRISP-DM. En esta fase se definió el objetivo de negocio: predecir la hospitalización de pacientes antes del alta en consulta para optimizar la asignación de recursos en el Centro de Salud Digital del Estado de Nayarit.



#### 3.b. 2. Comprensión de los Datos

Se analizó el dataset histórico de 1,010 registros con 27 variables clínicas, socioeconómicas y de estilo de vida. Se identificaron valores nulos, atípicos, inconsistencias de formato y desbalance de clases en la variable objetivo.




### 3.c. 3. Preparación de los Datos

Se aplicaron las siguientes acciones: eliminación de duplicados, corrección de formatos compuestos, homologación de unidades, estandarización, imputación de nulos, conversión de valores fuera de dominio y generación de **3 clusters de riesgo con K-Means** como características adicionales.



### 3.d. 4. Modelado


Se entrenaron tres algoritmos supervisados: **Árbol de Decisión**, **Naive Bayes** y **Reglas Apriori**. Previamente se aplicó sobremuestreo (oversampling) sobre la clase minoritaria y se seleccionaron las **10 características más relevantes** mediante la librería `feature_ranker`.



### 3.e. 5. Evaluación

Los modelos se evaluaron con división 70/30 estratificada, utilizando como métrica principal F1-Score. El Árbol de Decisión alcanzó un **F1 de 0.8308** y un **AUC = 0.8169**, superando claramente a Naive Bayes.

## Roc & AUC



### 3.f. 6. Recomendación y Limitaciones

Se recomienda integrar el modelo como apoyo al triage, acompañado de un panel visual con las variables clave. Se identifican limitaciones de tamaño muestral, recomendando una fase de monitoreo en producción antes de su adopción plena.




## 4. 04 RESULTADOS

### 4.a. Matriz de Confusión — Árbol de Decisión

La diagonal principal concentra la mayoría de las predicciones, indicando un buen nivel de concordancia entre valores reales y predichos. La **sensibilidad del 90.27 %** es el indicador clave: el modelo identifica correctamente a más de 9 de cada 10 pacientes que efectivamente requirieron hospitalización, minimizando los **falsos**


**negativos** — el mayor riesgo clínico en este contexto, pues un paciente en riesgo clasificado como “no hospitalizado” podría no recibir la atención adecuada.

Matriz de Confusión – Mejor Modelo: Árbol de Decisión




#### 4.b. Curva ROC Comparativa

El Árbol de Decisión alcanza un **AUC = 0.8169**, significativamente por encima de Naive Bayes y del umbral aleatorio (AUC = 0.50). Esto confirma que el modelo distingue casi perfectamente entre pacientes hospitalizados y no hospitalizados para este conjunto de datos clínicos, permitiendo fijar un umbral de decisión ajustable según la tolerancia del centro al riesgo de falsas alarmas (falsos positivos).



#### 4.c. Importancia de Características

La variable con mayor peso predictivo es la **edad** del paciente, con una importancia muy superior al resto. Le siguen la **presión sistólica** y los antecedentes de **hipertensión previa** y **diabetes previa**. Este orden coincide con el conocimiento clínico consolidado: la edad y las variables cardiovasculares son los principales determinantes de riesgo de hospitalización en atención primaria, validando la aplicabilidad clínica del modelo.



## 5. 05 CONCLUSIONES Y RECOMENDACIONES

**Mejor modelo:** El **Árbol de Decisión** es el modelo recomendado para implementación operativa, con **F1-Score = 0.8308**, exactitud del **81.67 %**, sensibilidad del **90.27 %** y **AUC > 0.80**. Su principal ventaja sobre el resto de modelos evaluados es la transparencia: las reglas de decisión son interpretables y pueden ser validadas directamente por el comité médico.

**Recomendación para el comité médico:** Integrar el modelo como herramienta de apoyo en el flujo de triage. Ante una predicción de alta probabilidad de hospitalización, el personal clínico debe priorizar la evaluación del paciente antes de emitir el alta. Se recomienda acompañar la predicción con un panel visual que muestre las variables clave (edad, presión arterial, antecedentes) para que el médico valide el resultado en segundos.

**Limitaciones honestas:**

- El dataset contiene solo **1,010 registros**; la generalización a otras regiones o periodos requiere validación prospectiva externa.
- La imputación de nulos introduce incertidumbre que solo puede cuantificarse con datos reales no balanceados en producción.
- Variables psicosociales, de adherencia al tratamiento y nivel socioeconómico no están disponibles, pero podrían mejorar sustancialmente la precisión del modelo.

6. 06 RECURSOS ADICIONALES

|  Recurso |  Enlace |  Descripción |
|---------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------|
| <b>Documentación técnica</b>                                                                | <a href="#">Abrir</a>                                                                      | Especificaciones del preprocesamiento, modelado y evaluación.                                   |
| <b>Demo en vivo</b>                                                                         | <a href="#">Abrir</a>                                                                      | Interfaz web interactiva para probar el modelo predictivo en tiempo real.                       |